Evaluación de la política pública Abogadas de las Mujeres en las agencias del Ministerio Público de la Ciudad de México

Juan Pablo Cordero Mayorga
Instituto Tecnológico Autónomo de México
Ciudad de México, México

Resumen: **En 2019, la Ciudad de México colocó abogadas en las agencias del Ministerio Público para acompañar a las mujeres que denuncian violencia. En 2025, la Secretaría de las Mujeres del Gobierno de México comenzó a replicar el programa en los otros 31 estados sin que yo encontrara una evaluación de impacto publicada. Este trabajo evalúa si la llegada de las abogadas aumentó las carpetas de investigación por violencia familiar en 54 unidades territoriales de la Ciudad de México. Una unidad es una agencia o un grupo de agencias que recibieron abogadas el mismo mes. Se utilizaron tres fuentes de información pública: los 121,995 registros de atención que el programa publica entre marzo de 2019 y marzo de 2022, las carpetas de investigación de la Fiscalía por agencia y mes y el censo de procuración de justicia del INEGI. El efecto se estimó con el método de imputación de Borusyak, Jaravel y Spiess en su versión Poisson. Este método utiliza las unidades que todavía no tenían abogadas para estimar cuántas carpetas habría abierto cada unidad en ausencia del programa.**

Los resultados muestran que, entre marzo y mayo de 2019, los únicos meses con suficientes unidades sin programa para usarlas como comparación, las carpetas fueron 27.7 % más de las que se habrían esperado sin el programa (p de permutación estratificada de 0.021). El resultado no se considera concluyente por cuatro razones. De los tres intervalos al 95 %, los dos que remuestrean unidades incluyen el cero, −0.2 % a +83.0 % con bootstrap y −11.0 % a +66.4 % con jackknife, mientras que el que solo invierte la permutación va de +4 % a +72 %. El efecto se concentra en las unidades que recibieron el programa en marzo, con +50 %. En las de abril y mayo no aparece. Parte del resultado viene de una caída en las unidades que todavía no lo tenían. Además, las diferencias previas aumentan conforme se acerca la llegada de las abogadas, aunque su prueba conjunta no las distingue del azar. Por simulación, el efecto mínimo detectable del diseño, el que detectaría en 80 % de los casos, resultó mayor que el efecto estimado: 32 % con el calendario real. Para la expansión nacional propongo sortear el orden de entrada de los estados en dos oleadas separadas por un año, escalonar también por agencia dentro de cada estado y fijar por escrito la fecha de llegada de cada abogada.

Palabras clave: **evaluación de políticas públicas, Abogadas de las Mujeres, violencia familiar, adopción escalonada, evaluación de impacto.**

I. Contexto

En la Ciudad de México existe una diferencia importante entre los delitos que ocurren y los que llegan a registrarse. La Fiscalía General de Justicia (FGJ) abre cientos de miles de carpetas de investigación al año. Sin embargo, una gran parte de los delitos no se denuncia. Esto hace que las políticas que buscan facilitar la denuncia sean especialmente relevantes, ya que un aumento en las denuncias debería reflejarse directamente en los registros de la Fiscalía. Para estudiar este problema busqué un programa con una fecha de inicio conocida, datos propios y dirigido a una población en la que se sabe que existe poca denuncia. Así llegué a la estrategia *Abogadas de las Mujeres en el Ministerio Público*.

El programa se anunció el 4 de marzo de 2019 con al menos una abogada con perspectiva de género en cada una de las 78 agencias del Ministerio Público (MP), según el comunicado de la Jefatura de Gobierno. Sin embargo, los registros muestran que las abogadas fueron llegando de manera gradual entre marzo y agosto de 2019. La Secretaría de las Mujeres de la Ciudad de México (SEMUJERES) publica cada atención realizada en el portal de datos abiertos de la ciudad. La ciudad ya contaba con otras formas de atención especializada que también aparecen en los datos de la Fiscalía, como la Agencia 75 y los Centros de Justicia para las Mujeres (CJM). En mayo de 2025, la Secretaría de las Mujeres del Gobierno de México abrió el registro de la Red Nacional de Abogadas de las Mujeres para las otras 31 entidades, según reportó la revista Proceso. Del programa en la Ciudad de México se han publicado principalmente cifras de atención: 158,469 asesorías y 57,706 carpetas en cuatro años. Para la expansión nacional no encontré una evaluación publicada ni un calendario de implementación.

La evaluación más cercana es la de las estaciones de policía para mujeres en India, que aumentaron 29 % las denuncias sin encontrar cambios en la incidencia medida por encuesta [1]. Como aquí, aprovecha que el programa comenzó en distintos momentos, lo que se conoce como adopción escalonada. Este tipo de implementación requiere cuidado porque una regresión tradicional con efectos fijos puede producir resultados sesgados cuando el efecto del programa cambia entre los grupos que lo reciben en diferentes fechas [2]. El método de imputación que utilizo evita ese problema. En esa evaluación no encontré cuál era el efecto mínimo que su diseño permitía detectar, aunque existen métodos para calcularlo [3]. Esto es especialmente importante en este caso porque el número de unidades y el corto periodo con grupos disponibles para comparación limitan el tamaño de los efectos que puedo identificar. Por eso, además

de estimar el efecto, este trabajo calcula qué tan grande tenía que ser para poder detectarlo.

II. Definición del problema

La pregunta tiene dos partes. La primera es si la llegada de las abogadas aumentó la apertura de carpetas por violencia familiar en las unidades territoriales, comparadas con las que todavía no tenían el programa y con delitos que este no debería afectar. La segunda es qué tan grande tenía que ser ese efecto para que pudiera detectarse con los datos disponibles. Esta segunda pregunta permite identificar qué tendría que cambiar en la expansión nacional para que sus resultados puedan evaluarse con mayor precisión. Dos decisiones lo determinan: el orden en que entran los estados y la forma de registrar la información. Ambas siguen abiertas y están en manos de la Secretaría de las Mujeres del Gobierno de México y de las instancias estatales.

El efecto principal compara las carpetas que realmente se abrieron con las que se habrían esperado sin el programa. El análisis se limita a marzo, abril y mayo de 2019, los meses en los que todavía había unidades sin abogadas que podían utilizarse como comparación. En esos tres meses hay 100 combinaciones de unidad territorial y mes con programa. Las unidades que recibieron abogadas en marzo aparecen durante tres meses, las de abril durante dos y las de mayo durante uno. Por eso, 60 de las 100 combinaciones corresponden a las unidades que recibieron el programa en marzo. El efecto mide entonces los primeros tres meses tras la llegada, sobre todo de la cohorte de marzo. Como el efecto compara totales de carpetas, el cálculo da mayor peso a las unidades con más carpetas. Quedan fuera las fiscalías especializadas, los meses posteriores a mayo, la calidad de la atención, la violencia misma y el efecto de la expansión nacional. El segundo objetivo es calcular el efecto mínimo detectable (MDE) de cada calendario de entrada.

Mi argumento central es que incluso un programa que publica cada atención realizada es difícil de evaluar de manera concluyente. El efecto estimado es similar al mínimo que los datos permitían detectar y se concentra en las unidades que recibieron el programa en marzo. Esto está relacionado con tres rasgos del despliegue y uno del registro: las unidades sin programa se agotaron en tres meses, el orden de llegada siguió el tamaño de las agencias, el conteo de cada agencia varía demasiado de un año a otro y el registro perdió el "no" durante varios meses. Los cuatro pueden tomarse en cuenta durante la expansión nacional.

III. Supuestos

S1. Un aumento en las carpetas de violencia familiar significa un aumento en la denuncia. Observo las carpetas de investigación por violencia familiar que abre cada agencia territorial del Ministerio Público, pero la pregunta es si las mujeres denuncian más. Un aumento puede deberse a más violencia, a que más mujeres deciden denunciar o a que el Ministerio Público registra mejor los mismos casos. Supongo que el programa actúa principalmente sobre la decisión de denunciar. En un periodo de tres meses es difícil pensar que la llegada de una abogada cambie la violencia familiar, pero sí puede cambiar la decisión de una mujer de presentar una denuncia, como ocurrió en India [1]. Para revisar si lo que estoy capturando es un cambio en el registro, utilizo como comparación los robos, que el programa no atiende (Sección V-B). Los robos detectarían un cambio de registro que afecte a todos los delitos, pero no una mejora exclusiva en el registro de la violencia familiar. Si el programa además redujo la violencia, mi efecto subestima el aumento en la denuncia.

S2. La fecha de llegada y la identidad de cada agencia están correctamente identificadas. El gobierno no publicó cuándo llegó cada abogada a su agencia. Ante la falta de un calendario oficial, defino la llegada como el primer mes en el que una agencia registra al menos una atención del programa. También necesito identificar la misma agencia en dos bases que utilizan nombres distintos. El programa registra los nombres manualmente mientras que la Fiscalía utiliza claves, así que construí una tabla para relacionarlos. Si una abogada llegó antes de su primera atención, el efecto se subestimaría y aparecería como un aumento antes de la llegada. Reviso la tabla en la Sección IV-A y la fecha con otra regla de llegada en la Sección V-D.

S3. Ningún cambio en el registro afectó a unas agencias y no a otras al mismo tiempo que la llegada de sus abogadas. Un cambio administrativo que modifique el número de carpetas registradas podría parecer un efecto del programa. Dentro de la ventana hubo uno: en enero de 2019, dos meses antes del lanzamiento, la Fiscalía cambió su catálogo de delitos, retiró 43 etiquetas que existían en diciembre de 2018 y dio entrada a 26 nuevas, por lo que publica una tabla de equivalencias para comparar delitos entre 2018 y 2019. La etiqueta de violencia familiar no es una de las que cambiaron y aparece sin interrupción desde 2016. Un cambio de catálogo afecta además a todas las agencias el mismo mes. El efecto de mes del estimador absorbe lo que le ocurre a la ciudad entera. Por eso el supuesto que necesito es el del encabezado y no que el registro se haya quedado quieto. Termino en febrero de 2020 porque después la comparación entre agencias comienza a romperse: durante la pandemia varias dejan de registrar carpetas y en 2021 la violencia familiar pasa a las Unidades de Atención Temprana. Las carpetas se cuentan en el mes en que fueron abiertas, no cuando ocurrió el hecho, porque el programa interviene cuando la mujer llega a denunciar.

S4. Las carpetas que aparecen en una agencia con abogadas son denuncias nuevas y no denuncias que cambiaron de sede. Una mujer puede denunciar violencia familiar en su agencia territorial, en la Agencia 75 o en los Centros de Justicia para las Mujeres. Si una mujer que antes acudía a una sede especializada comienza a denunciar en su agencia territorial porque ahí encuentra una abogada, la carpeta cambia de lugar, pero el total de denuncias de la ciudad no aumenta. Lo mismo puede ocurrir entre agencias territoriales si una ya tiene abogada y otra todavía no. En la Sección V-A reviso el traslado entre

agencias territoriales, que no lo puedo descartar.

S5. Sin el programa, las carpetas de cada agencia habrían crecido o caído en la misma proporción que las de las agencias que todavía no tenían abogadas. Ninguna agencia empezó a cambiar antes de recibir a su abogada. Este es el supuesto principal del análisis porque permite utilizar las agencias que todavía no tenían abogadas para estimar qué habría pasado en las que ya las tenían [4]. Hablar de la misma proporción no significa que todas deban tener el mismo número de carpetas. Si las carpetas de las agencias sin abogadas aumentan 10% en un mes, el supuesto es que cada agencia con abogadas habría aumentado aproximadamente 10% sobre su propio nivel. También necesito que el cambio no haya comenzado antes de la llegada. Si una agencia ya venía creciendo, parte de ese crecimiento podría terminar atribuido al programa. Las dos condiciones se ponen a prueba en la Sección V-C, donde aparece la principal limitación del análisis.

S6. Dentro de un grupo de agencias de tamaño parecido, el orden en que llegaron las abogadas no tuvo que ver con nada más que estuviera moviendo las carpetas. El orden de llegada no fue al azar: las agencias grandes recibieron abogadas antes que las chicas. Lo que supongo es que, una vez separadas las agencias en tres grupos de tamaño parecido, dentro de cada grupo el turno de cada agencia pudo haber sido cualquier otro. Esto importa porque de ahí sale la prueba principal del análisis: para saber si un aumento como el que estimé pudo aparecer por casualidad, reparto las fechas de llegada dentro de cada grupo 5,000 veces y cuento con qué frecuencia el azar produce un aumento igual de grande. Si dentro de los grupos el orden siguiera otro criterio que también mueve las carpetas, el valor p sería demasiado optimista. Para la segunda pregunta del trabajo, la de si el programa se podía evaluar, necesito además que los meses previos al programa, de enero de 2017 a febrero de 2019, muestren cómo se mueve una agencia cuando no le pasa nada. Sobre ese periodo simulo efectos de distintos tamaños para medir cuál es el más chico que este análisis habría podido detectar. Reviso el primer supuesto en la Sección V-A. El segundo es la base de la simulación de la Sección V-F.

IV. Metodología

A. *Los datos, las unidades y la ventana de análisis*

Usé tres fuentes oficiales. Del portal de datos abiertos de la Ciudad de México tomé las 121,995 atenciones registradas por SEMUJERES entre marzo de 2019 y marzo de 2022 y las carpetas de investigación de la FGJ por agencia y mes. Del INEGI tomé el Censo Nacional de Procuración de Justicia Estatal (CNPJE). Cada problema de los datos se documentó antes de decidir si la información podía utilizarse, requería un supuesto o debía descartarse.

El primer problema aparece en el registro de SEMUJERES. Durante 13 meses entre julio de 2020 y agosto de 2021 desaparece la respuesta que indica que no se abrió una carpeta y aumenta el número de campos vacíos (Figura 1). Como el panel utilizado para estimar el efecto termina en febrero de 2020, este problema no afecta la estimación. Solo afecta los cálculos posteriores de conversión, que reporto excluyendo esos meses.

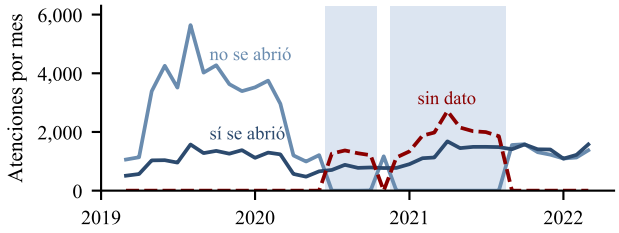


Figura 1: Atenciones del programa por mes según lo que el registro dice de la carpeta. En los meses sombreados el "no" desaparece y su lugar lo ocupa el "sin dato", mientras que el "sí" sigue su propio nivel. Base de SEMUJERES.

El segundo problema es identificar la misma agencia en las dos fuentes. SEMUJERES registra los nombres manualmente, por ejemplo `CUJ 1 Y 2` o `AZC-2 y 4`, mientras que la Fiscalía utiliza códigos como `CJ-1` y `AZ-4`. Normalicé estos nombres y los relacioné con los códigos de la FGJ. Cuando una misma pareja de abogadas atiende dos agencias, ambas se consideran una sola unidad porque comparten la misma fecha de llegada. Las 67 etiquetas territoriales del programa se convierten así en 57 unidades que cubren 72 de las 78 agencias anunciadas por el gobierno.

Para revisar estas equivalencias comparé las carpetas reportadas por ambas fuentes. Las carpetas que SEMUJERES atribuye al programa no deberían superar las carpetas de violencia familiar que la Fiscalía registra en la misma agencia y mes. Esta condición se cumple en 775 de 809 casos. La fecha de llegada de las abogadas se define como el primer mes en que cada unidad registra al menos una atención.

La muestra también excluye tres unidades cuyos datos previos no permiten construir una comparación confiable, porque tenían meses sin registros o saltos abruptos en su nivel de carpetas, o porque recibieron abogadas después de la ventana de análisis. La regla solo mira los meses anteriores a la llegada de las abogadas. En una unidad cuya clave deja de aparecer en los datos de la Fiscalía, esos meses se tratan como faltantes y no como ceros.

La muestra final contiene 54 unidades observadas durante 38 meses. Las abogadas llegaron de manera gradual entre marzo y agosto de 2019. Las primeras 20 unidades entraron en marzo. Las unidades que todavía no tenían el programa y podían utilizarse como comparación disminuyen rápidamente: 34 en marzo, 20 en abril, 8 en mayo y solo 2 en junio. Como el análisis exige al menos 5 unidades sin programa para estimar qué habría ocurrido sin las abogadas, el efecto puede estimarse únicamente hasta mayo de 2019.

B. *Hipótesis*

Definí seis resultados que esperaría encontrar si el programa realmente aumentaba la denuncia. La lista completa la formalicé

después, al revisar el análisis. **H1:** después de la llegada de las abogadas, las carpetas de violencia familiar aumentan respecto a lo que se habría esperado sin el programa. **H2:** los robos, que el programa no atiende, no muestran el mismo aumento. **H3:** el aumento no aparece antes de la llegada de las abogadas. **H4:** el resultado se observa en distintos grupos de unidades y no depende únicamente de las que recibieron el programa primero. **H5:** la proporción de atenciones que termina en una carpeta refleja diferencias en el desempeño de las agencias y no solamente cuántas mujeres atienden. **H6:** el diseño permite detectar efectos de entre 20 % y 30 %, un rango cercano al aumento que se encontró en India. El contraste principal es el efecto sobre las carpetas de violencia familiar con permutación estratificada. H2 a H4 buscan refutarlo. La pregunta y el placebo de robos forman parte del diseño desde el inicio. H1 se mide con el estimador, H2 con el placebo de robos, H3 con la prueba de tendencias previas, H4 con el efecto por cohorte de llegada, H5 con la conversión y H6 con la simulación de potencia.

C. *Cómo estimé el efecto*

Para estimar el efecto utilicé el método de imputación de Borusyak, Jaravel y Spiess [4] en versión Poisson. El modelo utiliza las 1,469 combinaciones de unidad y mes en las que todavía no había abogadas para aprender dos cosas: el nivel normal de carpetas de cada unidad y los cambios que afectan a toda la ciudad en cada mes. Con estos dos componentes estima cuántas carpetas habría abierto una unidad si las abogadas no hubieran llegado. Por ejemplo, VC-3 recibió el programa en marzo de 2019. El modelo estimó que ese mes habría abierto 21.1 carpetas sin el programa y se observaron 38.

Formalmente, para los meses sin programa estimo $E[Y_{it}(0)] = a_i b_t$. Después utilizo $\hat{a}_i \hat{b}_t$ para estimar las carpetas esperadas sin programa en cada unidad que ya tenía abogadas. El efecto compara el total observado con este total esperado: $\hat{\tau} = \sum Y_{it} / \sum \hat{a}_i \hat{b}_t - 1$. Elegí Poisson porque los datos son conteos, existen meses con cero carpetas y una unidad típica abre alrededor de 16 al mes.

V. Resultados y discusión

Presento los resultados en el orden de las hipótesis. En cada una digo qué prueba usé y de dónde sale cada cifra.

A. *H1: más carpetas de las esperadas*

Entre marzo y mayo de 2019, las unidades que ya contaban con el programa abrieron 2,793 carpetas de investigación por violencia familiar según los datos de la Fiscalía. Para esas mismas unidades y meses el estimador por imputación calcula que se habrían abierto 2,187 sin el programa. La diferencia equivale a un aumento de +27.7 %. Solo puedo medir esos tres meses porque desde junio quedan menos de 5 unidades sin abogadas contra las cuales comparar.

Un aumento así también podría salir por azar. Para saber qué tan probable es, repetí el análisis 5,000 veces cambiando las fechas de llegada entre las unidades [5]. Si las abogadas no hubieran hecho nada, cualquiera de esos calendarios sería tan válido como el real. Las fechas no se intercambian entre todas las unidades porque las más grandes recibieron abogadas antes (correlación de rangos entre tamaño y mes de llegada de -0.37, p = 0.006). Por eso las divido en tres grupos según su total de carpetas de 2018 y cambio las fechas solo dentro de cada grupo. En 102 de los 5,000 calendarios apareció un efecto igual o mayor en valor absoluto, un valor p de 0.021. Como elegir tres grupos también es una decisión mía, repetí la prueba con uno y con nueve grupos. En los dos casos el valor p sigue por debajo de 0.05.

El rango del efecto depende de qué incertidumbre se mida, así que reporto tres intervalos al 95 %. El primero sale de la misma permutación [5]: reúne los efectos que esa prueba no rechazaría y va de +4 % a +72 %. Para construirlo hay que suponer que el efecto es igual en todas las unidades. Los otros dos preguntan qué pasaría si las unidades fueran otras. Con bootstrap, que vuelve a sortear las unidades con reemplazo, va de -0.2 % a +83.0 %. Con jackknife, que quita una a la vez, va de -11.0 % a +66.4 %. Estos dos incluyen el cero.

El +27.7 % compara dos grupos en los mismos meses, así que puede venir de que las unidades con abogadas subieron o de que las de comparación bajaron. Para saber cuál pasó comparé cada grupo contra el mismo mes de 2018, sin ningún modelo. En marzo de 2019 las unidades con abogadas abrieron +28.8 % carpetas respecto a un año antes, mientras que las que todavía no tenían abogadas abrieron -20.8 %. En abril pasó algo parecido: +2.9 % contra -25.0 %. Buena parte de la diferencia viene entonces de que las unidades de comparación cayeron, no solo de que las otras subieran.

Una explicación de esa caída es que algunas mujeres dejaran de denunciar en su agencia y fueran a una vecina que ya tenía abogadas. Si fuera así, las carpetas solo habrían cambiado de lugar y el efecto estaría inflado. **S4** supone que esto no pasa. Para revisarlo dejé como comparación solo a las unidades sin programa que no tienen ninguna agencia con abogadas en su alcaldía. Con ellas el efecto del mes de marzo, que por sí solo es de +62.8 %, baja a +44.6 %. Baja, pero sigue siendo grande. No lo tomo como prueba de un traslado porque esas vecinas ya venían cayendo antes del lanzamiento.

Por último, el registro del programa pone un techo. En las unidades y meses donde estimé el efecto la Fiscalía abrió 2,793 carpetas de violencia familiar y el programa registra que 1,330 de ellas (47.6 %) pasaron por una abogada. Aun si ninguna se hubiera abierto sin abogada, se habrían abierto las otras 1,463, así que el efecto no puede pasar de 2,793/1,463 $-$ 1 = +91 %. El +28 % cabe, pero implica que 46 % de las carpetas con abogada no habrían existido sin ella. Este techo supone que el programa solo abre carpetas a través de sus abogadas.

El resultado tiene el signo que pedía **H1**: hay más carpetas de las esperadas y el aumento es posible. No alcanza para atribuírselo al programa, porque dos de los tres intervalos incluyen el cero y parte del contraste viene de la caída de las comparaciones.

B. H2: los robos no suben igual

Si lo que estoy midiendo fuera un cambio en cómo la Fiscalía registra todas las denuncias, los delitos que las abogadas no atienden también subirían. Por eso repetí el mismo estimador y la misma permutación con las carpetas por robo. Aumentan +5.1 % (p = 0.36), con un intervalo bootstrap de −4.0 % a +13.0 % que no alcanza el +27.7 % de la violencia familiar. Ese aumento tampoco parece venir de marzo de 2019. Viene de que en las unidades que entraron primero los robos ya venían subiendo desde antes, como muestran los lanzamientos ficticios del siguiente párrafo.

El segundo placebo mueve la fecha en lugar del delito. Corrí el calendario real entre 3 y 20 meses hacia atrás, a 2017 y 2018, cuando el programa no existía. Con esos 18 lanzamientos ficticios repetí el estimador. En violencia familiar promedian −3.9 % y ninguno alcanza la estimación principal. En robos los mismos lanzamientos promedian +4.5 % y 15 de 18 salen positivos, lo que confirma esa tendencia propia. En la violencia familiar no aparece. **H2** se cumple.

C. H3: nada subía antes de que llegaran

La principal dificultad aparece al revisar qué ocurría antes de la llegada de las abogadas. Es lo que pide **H3** y lo que supone **S5**: que sin abogadas cada unidad habría seguido el ritmo de las que aún no las tenían. El estimador principal solo puede medir los meses −6 a −4, porque antes no quedan suficientes unidades sin programa. Ahí promedia +1.2 %. Los meses más cercanos a la llegada los revisé con la prueba de tendencias previas que proponen Borusyak, Jaravel y Spiess [4]. Es un modelo aparte del estimador: una regresión Poisson con efectos fijos de unidad y de mes más un indicador por cada uno de los últimos meses antes de la llegada. Una prueba de Wald con errores agrupados por unidad, que evalúa todos los indicadores a la vez, no permite rechazar que esos meses sean cero (p = 0.30 con tres meses y 0.27 con seis). Uno por uno, en cambio, crecen conforme se acerca la fecha: +9 %, +25 % y +38 % en los meses −3, −2 y −1 (Figura 2). El último supera al efecto estimado, aunque viene de otro modelo. Si los estimo por separado para cada cohorte de llegada, la subida previa viene de la cohorte de marzo. Los errores estándar son grandes, así que estas cifras no afirman que hubiera tendencia previa [6], pero impiden descartarla.

Busqué una última señal en la trayectoria de cada unidad, esta vez sin decirle al método cuándo llegaron las abogadas. Con el detector de puntos de cambio PELT (*pruned exact linear time*) revisé la serie mensual de cada unidad de enero de 2017 a febrero de 2020. Si el programa movió las carpetas, los cambios deberían caer cerca de la llegada más seguido de lo que daría el azar. De las 54 unidades, 12 tienen un cambio al alza en el mes de llegada o el siguiente. Para saber si es inusual reasigné las fechas como en la permutación de H1, sin mover los cambios. Con esas fechas se esperan 7.7 coincidencias y solo 3.2 % de los repartos producen 12 o más. En robos aparece 1 (p = 0.44).

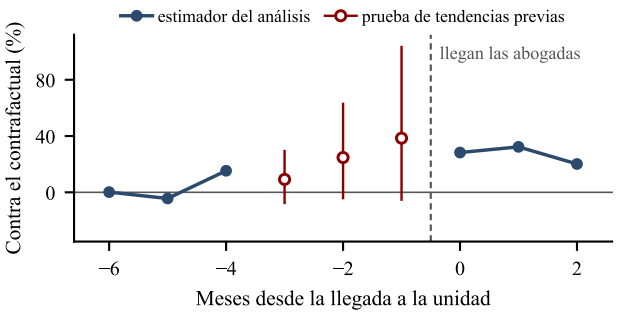


Figura 2: Efecto por mes desde la llegada de las abogadas (mes 0). Puntos sólidos: estimador por imputación. Puntos huecos: prueba de tendencias previas, con su intervalo al 95 %. Los dos vienen de modelos distintos.

Este ejercicio lo uso solo como evidencia exploratoria. Corrí 36 versiones de la prueba, combinando nueve sensibilidades del detector con cuatro ventanas alrededor de la llegada. Con el ajuste de Westfall y Young, que corrige el valor p por haberlas probado todas, el de la versión principal sube de 0.032 a 0.145. Además, si muevo las fechas un mes hacia atrás vuelvo a encontrar 12: la prueba ve cambios cerca de la entrada pero no distingue el mes exacto, igual que el adelanto del mes −1. **H3** no se puede confirmar y es la limitación más seria del análisis.

D. H4: el aumento en todas las cohortes de llegada

El resultado no depende de una sola agencia. Al retirar una unidad a la vez, como en el jackknife de H1, el efecto se mantiene entre +17 % y +38 % y nunca cambia de signo. Tampoco depende de las decisiones del análisis que muestra la parte de arriba de la Tabla I, como la fecha de entrada, el mínimo de unidades de comparación o la ventana de entrenamiento: con todas ellas queda entre +20.7 % y +55.1 %.

Sí depende de cuándo entraron. Al estimar el efecto de cada cohorte de llegada por separado, las unidades que recibieron abogadas en marzo muestran +50 %, las de abril +0.5 % y las de mayo −20 % (Tabla I, abajo). Excluyendo la cohorte de marzo el efecto conjunto pasa a −3.2 %. Esa primera cohorte reúne a las unidades más grandes y representa 58 % del contrafactual. Es la misma de la que viene la subida previa de H3. **H4**, que pedía encontrar el resultado en distintas cohortes de llegada, no se sostiene.

E. H5: la conversión como medida de desempeño

La conversión, la proporción de atenciones que termina en una carpeta, es la cifra con la que el programa mide su éxito. Según su propio registro pasó de 24.2 % en 2019 a 51.1 % entre septiembre de 2021 y marzo de 2022. Parece una mejora, pero las carpetas al mes solo subieron 26.4 % mientras las atenciones caían 40.2 %. Al separar los dos cambios, 69 % del aumento viene de que se registraron menos atenciones.

La conversión también cambia mucho de una agencia a otra. Entre las 56 con al menos 100 atenciones va de 3.3 % a 38.3 %. Comparé cada una con lo que se esperaría por su número de

Tabla I: Sensibilidad del efecto a las decisiones del análisis. Arriba, variantes con las tres cohortes de llegada juntas. Abajo, cada cohorte de llegada por separado.

Variante del análisis	Efecto (%)
Estimación principal (54 unidades)	+27.71
Entrada = primer mes con 10 o más atenciones	+20.7
Mínimo de 3 unidades sin programa (mismos meses)	+27.71
Mínimo de 10 (deja solo marzo y abril)	+55.1
Entrenamiento desde septiembre de 2018	+27.9
Exclusión con toda la ventana (52 unidades)	+27.74
Relativo al resto de carpetas de la unidad	+23.8
Sin la cohorte de marzo	−3.2
Solo la cohorte de marzo (20 unidades)	+50.1
Solo la cohorte de abril (14 unidades)	+0.5
Solo la cohorte de mayo (12 unidades)	−19.8

atenciones y las diferencias siguen siendo mayores de lo que explica su tamaño.

Tampoco se explican porque unas agencias reciban casos más graves. Comparando dentro de cada agencia, las atenciones con riesgo feminicida sí terminan más seguido en carpeta. Aun así, 40.6% de las 800 que tuvieron ese riesgo no terminó en una. Esa proporción va de 18% a 68% según la agencia.

H5 no se sostiene como la planteé: la conversión mezcla el volumen de atenciones, la composición de los casos y diferencias entre agencias, así que no puede leerse directamente como desempeño.

F. H6: un diseño que detecte entre 20% y 30%

Queda la segunda pregunta: si el diseño podía distinguir del azar un efecto como este. Para responderla calculé el efecto mínimo detectable (MDE), el efecto más chico que la permutación de H1 detecta en 80% de los casos con un nivel de 5%. Lo hice por simulación con los meses anteriores al programa, de enero de 2017 a febrero de 2019 [3]. Simulo la llegada de las abogadas en marzo de 2018, agrego a las unidades con programa un porcentaje conocido de carpetas y aplico la misma prueba. Repito el ejercicio 2,000 veces por cada tamaño de efecto y cuento en qué proporción se rechaza el efecto cero (Figura 3).

Con el calendario real ("como se hizo" en la Figura 3) el MDE es 32.2%, por encima del +28% que estimé. Un efecto verdadero de 20% se habría detectado 40% de las veces y uno de 10%, 12%. El problema es el ruido de cada agencia: sin ningún programa, sus carpetas cambian entre −46% y +64% de un año a otro (percentiles 5 y 95). Por eso un resultado nulo tampoco habría demostrado que el programa no funcionaba.

Otro calendario no lo habría resuelto. Simulé tres que el programa pudo haber usado, que reparten las unidades en orden alfabético y dan casi lo mismo: 33% con 12 cohortes mensuales, 33% con 4 cohortes trimestrales y 35% si la mitad de las agencias espera un año. Con ese mismo reparto el calendario real da 28%, así que ninguno mejora al real.

¿Y si se sortearan los estados? La expansión nacional podría evaluarse sorteando qué estados entran primero. Para ver si así se detectaría un efecto como este, repetí la simulación con los 31 estados distintos de la Ciudad de México, con los delitos de violencia familiar que el censo de procuración de justicia del INEGI (CNPJE) registra en carpetas de 2020 a 2024, sorteados en dos grupos de tamaño parecido. El MDE baja a 18% (curva roja). Pero ese porcentaje es sobre todos los delitos registrados en el estado. Las abogadas solo están en las agencias territoriales, que en la ciudad abren 59% de esas carpetas. Si en los estados pasa igual, un 18% estatal equivale a cerca de 30% en cada agencia con abogada, casi el mismo umbral que en la ciudad.

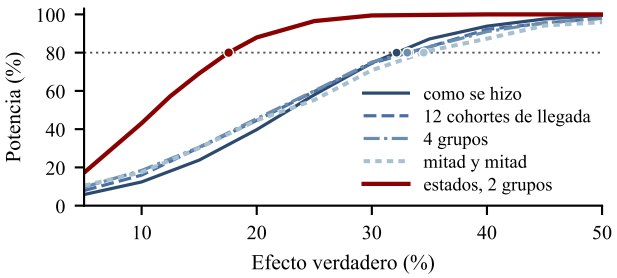


Figura 3: Probabilidad de que la prueba del análisis detecte un efecto verdadero de cada tamaño, según el calendario de entrada. Las curvas azules simulan las agencias de la ciudad con un lanzamiento ficticio en marzo de 2018. La roja simula los estados sorteados en dos grupos, con el efecto medido sobre el total de cada estado. El punto sobre la línea de 80% marca el MDE de cada calendario. La curva "como se hizo" conserva cuántas unidades de cada tercil de tamaño entran en cada cohorte de llegada. Cada punto resume 2,000 simulaciones.

H6 pedía detectar efectos de entre 20% y 30%, así que no se cumple: con 30% la potencia es de 75%, por debajo del 80%.

G. En conjunto

El resultado es un indicio positivo que no es concluyente. El +27.7% tiene el signo esperado, es mayor que el de los robos y sigue positivo al retirar cualquier unidad. Al mismo tiempo, dos de los tres intervalos incluyen el cero, el resultado se concentra en la cohorte de marzo, parte del contraste viene de la caída de las comparaciones y no puede descartarse una tendencia previa. Y aunque todo eso se resolviera, el diseño solo detectaba con confianza efectos de 32% o más. Es compatible con que las abogadas hayan aumentado la apertura de carpetas. No alcanza para atribuirles el aumento.

VI. Conclusiones

El +28% es un indicio positivo que no es concluyente, por las cuatro razones de la Sección V. A eso se suma la respuesta a la segunda pregunta: el diseño solo detectaba efectos similares al que estimé o mayores, 32% con el calendario real (Sección V-F).

Tres rasgos del despliegue y uno del registro lo volvieron difícil de evaluar. Ningún análisis posterior los corrige. Las unidades de comparación se agotaron en tres meses del calendario. El orden de llegada siguió el tamaño de las agencias. El conteo de cada agencia varía demasiado de un año a otro, aun sin

programa. Y el registro perdió el "no" durante 13 meses, lo que obliga a medir la conversión sin esos meses. Los cuatro pueden tomarse en cuenta antes de arrancar, así que mis recomendaciones son de diseño y de registro, en orden de prioridad.

1. **Sortear el orden de entrada de los estados en al menos dos oleadas separadas por un año, dentro de grupos de tamaño parecido.** Va primero por validez: da un grupo de comparación que no depende del orden por tamaño ni de las reorganizaciones de una sola fiscalía, los dos problemas que no resolví en la ciudad. En potencia no gana. Cuesta planeación, no presupuesto, pero retrasa un año a la mitad de los estados.
2. **Escalonar también dentro de cada estado por agencia y fijar la fecha de entrada por escrito.** Con cientos de agencias en lugar de 54 unidades, el MDE por agencia podría bajar, aunque no lo simulé. También habría con qué comparar más allá de tres meses.
3. **Agregar seis campos al registro desde el primer día:** folio único de atención, fecha exacta, clave oficial de la agencia, número de carpeta cuando se abre, un sí o no obligatorio sin opción "sin dato" y el nivel de riesgo. Son cambios de formulario.
4. **Dejar de usar la conversión como indicador de éxito.** Reportar por separado atenciones y carpetas, cada una contra el total de violencia familiar de la agencia.
5. **Registrar las medidas de protección y revisar primero una lista corta de agencias.** El registro tiene un campo de solicitud de medidas, pero casi solo se llena cuando hay carpeta. Sin un registro completo no se sabe si hubo protección por otra vía en las atenciones con riesgo feminicida sin carpeta. Empezaría por las unidades con la conversión más baja para su tamaño (IZP-9 Y 10, TLP-1, COY-5), sin leer esa lista como prueba de que funcionen peor.

Tres cosas pueden alterar ese orden. La primera recomendación pierde sentido si la expansión ya arrancó al mismo tiempo en todos los estados, caso en el que la segunda pasa a ser la principal. Si lo que se busca es reducir la violencia y no aumentar la denuncia (**S1**), el resultado hay que medirlo con encuestas de victimización. Las cifras de potencia suponen un efecto parejo entre estados. Con la heterogeneidad que vi entre cohortes de llegada, el MDE del promedio probablemente sería mayor. Queda un riesgo ajeno a mi diseño: el censo lo autorreporta cada fiscalía, así que un cambio de sistema de registro durante la expansión se confundiría con un efecto.

Como trabajo futuro quedan simular el despliegue real con efectos heterogéneos entre cohortes de llegada, simular una expansión por agencias en varios estados, repetir la simulación estatal con la incidencia mensual del Secretariado Ejecutivo y verificar cómo arrancó la expansión en cada estado.

Referencias

[1] S. Amaral, S. Bhalotra, y N. Prakash, «Gender, Crime and Punishment: Evidence from Women Police Stations in India», CESifo, Working Paper 9002, 2021.

[2] A. Goodman-Bacon, «Difference-in-differences with variation in treatment timing», *Journal of Econometrics*, vol. 225, n.º 2, pp. 254-277, 2021.

[3] F. Burlig, L. Preonas, y M. Woerman, «Panel data and experimental design», *Journal of Development Economics*, vol. 144, p. 102458, 2020.

[4] K. Borusyak, X. Jaravel, y J. Spiess, «Revisiting event-study designs: Robust and efficient estimation», *The Review of Economic Studies*, vol. 91, n.º 6, pp. 3253-3285, 2024.

[5] P. R. Rosenbaum, *Observational Studies*, 2.ª ed. Nueva York: Springer, 2002.

[6] J. Roth, «Pretest with caution: Event-study estimates after testing for parallel trends», *American Economic Review: Insights*, vol. 4, n.º 3, pp. 305-322, 2022.

Apéndice A
Declaración de uso de IA generativa

Usé un asistente de IA generativa (Claude, de Anthropic) en cuatro tareas. En el código, me ayudó a escribir y depurar los scripts de limpieza, estimación y simulación y la aplicación web. En la redacción, produjo borradores de la documentación y de este reporte a partir de mis resultados, que luego corregí. En la revisión, lo usé para buscar referencias y para señalar cifras del texto que no coincidían con los archivos de resultados. Por último, lo usé para auditar los cálculos. La auditoría encontró errores de implementación y de interpretación, las correcciones se aplicaron en los scripts y todas las cifras de este reporte se leen de sus resultados. Elegí la pregunta, los supuestos y la interpretación. Soy responsable del contenido. Reviso cada cifra contra los archivos de resultados y cada referencia contra su fuente. Aun así se me fue el resumen del estudio de Perú en la primera versión y lo corregí después.

Apéndice B
Reproducibilidad

El repositorio del proyecto incluye el código, las instrucciones para ejecutarlo y los resultados de los que este documento toma cada cifra, con las semillas fijas para que se reproduzcan tal como aparecen aquí. El análisis se acompaña de una aplicación web con las mismas cifras que este documento. El repositorio es público y está en https://github.com/Cord210802/abogadas-mujeres.